Trabalho Prático 2 Árvores binárias ordenadas aleatoriamente

Licenciatura em Engenharia Informática
UC 40437 - Algoritmos e Estruturas de Dados
Ano letivo 2018/2019

Trabalho realizado por: 88808 - João Miguel Nunes de Medeiros e Vasconcelos 88886 - Tiago Carvalho Mendes

Aveiro, 31 de dezembro de 2018

Índice

ntroduçãontrodução	3
Código para o estudo das árvores binárias	4
Descrição das funções desenvolvidas	13
Código para representação dos gráficos	14
Análise de resultados	17
Conclusões	24
Referências	25

Introdução

O presente documento destina-se a descrever detalhadamente a abordagem utilizada para resolver o problema proposto como segundo trabalho prático da unidade curricular de Algoritmos e Estruturas de Dados da Universidade de Aveiro, cujo tema era o estudo de Árvores binárias ordenadas aleatoriamente.

O objetivo deste trabalho é então estudar empiricamente árvores binárias aleatórias ordenadas. Especificamente, pretendemos para uma árvore com n nodes, calcular e perceber como evolui quando o n aumenta:

- A altura média de uma árvore;
- O número médio de folhas;
- O custo médio de procurar por um item de informação presente na árvore (hit);
- O custo médio de procurar por um item de informação que não esteja presente na árvore (miss);

Para suportar as nossas conclusões apresentamos gráficos e tabelas com os resultados.

```
//
// Tomás Oliveira e Silva, AED, November 2018
// 88808 João Miguel Nunes de Medeiros e Vasconcelos
// 88886 Tiago Carvalho Mendes
// empirical study of random ordered binary trees
#include <math.h>
#include <stdio.h>
#include <stdlib.h>
#include "elapsed time.h"
//
// each node of our ordered binary tree will store a long integer
// the root of the tree should be declared as follows (set initially to an empty tree):
// tree_node *root = NULL;
//
typedef struct tree_node
struct tree_node *left; // pointer to the left branch (a sub-tree)
struct tree_node *right; // pointer to the right branch (a sub-tree)
struct tree_node *parent; // pointer to the parent node (NULL for the root of the tree)
long data;
                   // the data item (we use a long here)
tree_node;
```

```
//
// insert a node in the tree (it is assumed that the tree does not store repeated data)
// use it as follows (example):
// insert_node(&root,&new_node);
//
static void insert_node(tree_node **link,tree_node *n)
tree_node *parent;
parent = NULL;
while(*link != NULL)
 if(n->data == (*link)->data)
  fprintf(stderr,"insert node: %ld is already in the tree\n",n->data);
  parent = *link;
 link = (n-)data < (*link)-)data) ? &((*link)-)left) : &((*link)-)right); // select branch
}
*link = n;
n->parent = parent;
n->left = n->right = NULL;
//
// count the number of leaves of the tree
// use if as follows (example):
// int n_leaves = count_leaves(root);
//
static int count_leaves(tree_node *link)
int leafcount;
if(link==NULL){
 return 0;
else if(link->left==NULL && link->right==NULL){
 return 1;
}
else{
 leafcount=count_leaves(link->right)+count_leaves(link->left);
return leafcount;
}
```

```
//
// compute the height of the tree
// use if as follows (example):
//
// int height = tree_height(root);
//
static int tree_height(tree_node *link)
{ int height,height_left,height_right;
if (link==NULL){
 return 0;
}
else{
 height_left=tree_height(link->left);
 height_right=tree_height(link->right);
 if (height_left>=height_right)
  height=height_left+1;
  height=height_right+1;
}
return height;
//
// recursive function used to search for the location of a data item
// use if as follows (example):
// tree_node *node = search_tree(root,data);
//
static int search_counter;
tree_node *search_tree(tree_node *link,long data)
{
search_counter++;
if(link == NULL)
 return NULL;
if(link->data == data)
 return link;
return search_tree((data < link->data) ? link->left : link->right,data);
```

```
// assuming that each data item is searched for with equal probability, compute the average number
// of recursive function calls to the search tree() function when
// 1) the search is successful (a hit)
// 2) the search is not successful (a miss)
// use them as follows (example):
//
// double average_calls_on_hit = (double)count_function_calls_on_hit(root,0) / (double)number_of_nodes;
// double average calls on miss = (double)count function calls on miss(root,0) / (double)number of nodes;
//
static int count_function_calls_on_hit(tree_node *link,int level)
{ int count;
if (link==NULL){
 return 0;
count = level+1;
if(link->left!=NULL)
 count+=count_function_calls_on_hit(link->left,level+1);
if(link->right!=NULL)
 count+=count_function_calls_on_hit(link->right,level+1);
return count;
}
static int count_function_calls_on_miss(tree_node *link,int level)
{ int count=0;// tenho que inicializar
if (link==NULL){
 count=level+1;
 return count;
 count+=count_function_calls_on_miss(link->right,level+1);
count+=count_function_calls_on_miss(link->left,level+1);
 return count;
```

```
// random permutation of the n numbers 1, 3, 5, ..., 2*n-1
// use if as follows (example):
// int n = 100;
// int a[n];
// rand_perm(n,&a[0]);
static void rand_perm(int n,int *a)
int i,j,k;
for(i = 0; i < n; i++)
 a[i] = 2 * i + 1;
for(i = n - 1; i > 0; i--)
 j = (int)floor((double)(i + 1) * (double)rand() / (1.0 + (double)RAND_MAX)); // range 0..i
 k = a[i];
 a[i] = a[j];
 a[j] = k;
}
 return count;
```

```
//
// main program
int main(int argc,char **argv)
int details = (argc == 3 \&\& argv[1][0] == '-' \&\& argv[1][1] == 'a' \&\& atoi(argv[2]) > 0) ? 1 : 0;
int n experiments = 1000; // TO DO: use more (1000000 should take 2 to 3 hours)
FILE *file;
                                // location of minima and maxima
file = fopen("Data.csv", "w");
 fprintf(file,"%s,%s,%s,%s,%s,%s,\n","n","maximum tree height (mean)","number of leaves (mean)","calls om hit (mean)","calls on miss
(mean)");
srandom(1u); // ensure reproducible results
printf("
                         data for %d random trees\n",n_experiments);
printf("
             maximum tree height number of leaves calls on hit calls on miss\n");
printf("
printf(" n min max mean std min max mean std mean std\n");
printf("-----\n");
for(int n_log = 1 * 10;n_log <= 4 * 10;n_log++)
 int n = (int)round(pow(10.0,(double)n_log / 10.0)); // the number of nodes of the tree
 int a[n];
                               // the nodes' data
 tree_node *root,nodes[n];
                                        // the root and the storage space for the nodes of the tree
 int h_height[n + 1];
                                    // for an histogram of the heights of the random trees
 int h_leaves[n + 1];
                                  // for an histogram of the number of leaves of the random trees
 double mean, std;
                                    // for mean and standard deviation computations
 double x,hit[2],miss[2];
                                     // for the average number of hits and misses
 int m,M;
 printf("%6d",n);
 fprintf(file,"%6d,",n);
 // the example in the slides
 if(n == 10)
 {
  root = NULL;
  nodes[0].data = 3l; insert_node(&root,&nodes[0]);
  nodes[1].data = 1l; insert_node(&root,&nodes[1]);
  nodes[2].data = 9I; insert_node(&root,&nodes[2]);
  nodes[3].data = 7l; insert node(&root,&nodes[3]);
  nodes[4].data = 5l; insert node(&root,&nodes[4]);
  if(count leaves(root) != 2)
   fprintf(stderr,"count leaves() returned a wrong value\n");
  if(tree height(root) != 4)
   fprintf(stderr,"tree_height() returned a wrong value\n");
   exit(1);
```

```
search counter = 0;
 for(int i = 1; i \le 9; i += 2)
  if(search_tree(root,(long)i) == NULL)
   return 1; // impossible if the program is correct
 if(count_function_calls_on_hit(root,0) != search_counter)
  fprintf(stderr,"count_function_calls_of_hit() returned a wrong value\n");
  exit(1);
 }
 search counter = 0;
 for(int i = 0;i \le 10;i += 2)
  if(search_tree(root,(long)i) != NULL)
   return 1; // impossible if the program is correct
 if(count_function_calls_on_miss(root,0) != search_counter)
  printf("%d -- %d",count_function_calls_on_hit(root,0),search_counter);
  fprintf(stderr,"count\_function\_calls\_of\_miss() \ returned \ a \ wrong \ value \ "");
  exit(1);
 }
}
// the experiments
//
for(int i = 0;i <= n;i++)
 h_height[i] = h_leaves[i] = 0;
hit[0] = hit[1] = miss[0] = miss[1] = 0.0;
for(int n_experiment = 0;n_experiment < n_experiments;n_experiment++)</pre>
 rand_perm(n,&a[0]);
 root = NULL;
 for(int i = 0;i < n;i++)
  nodes[i].data = (long)a[i];
  insert_node(&root,&nodes[i]);
 h_height[tree_height(root)]++;
 h_leaves(count_leaves(root)]++;
 x = (double)count_function_calls_on_hit(root,0) / (double)n; // there are n nodes
```

```
hit[0] += x;
 hit[1] += x * x;
 x = (double)count\_function\_calls\_on\_miss(root,0) / (double)(n + 1); // there are n+1 NULL pointers
 miss[0] += x;
 miss[1] += x * x;
//
// output summary
mean = std = 0.0;
m = n + 1;
M = -1;
for(int i = 0; i <= n; i++)
 if(h_height[i] != 0)
 {
  mean += (double)i * (double)h_height[i];
  std += (double)i * (double)i * (double)h_height[i];
  if(i < m) m = i;
  if(i > M) M = i;
mean /= (double)n_experiments;
std /= (double)n_experiments;
std = sqrt(std - mean * mean);
printf(" %3d %3d %7.4f %6.4f",m,M,mean,std);
fprintf(file,"%7.4f,",mean);
mean = std = 0.0;
m = n + 1;
M = -1;
for(int i = 0; i <= n; i++)
 if(h_leaves[i] != 0)
 {
  mean += (double)i * (double)h_leaves[i];
  std += (double)i * (double)i * (double)h_leaves[i];
  if(i < m) m = i;
  if(i > M) M = i;
mean /= (double)n_experiments;
std /= (double)n_experiments;
std = sqrt(std - mean * mean);
```

```
printf(" %5d %5d %10.4f %8.4f",m,M,mean,std);
 fprintf(file,"%10.4f,",mean);
 mean = hit[0] / (double)n_experiments;
 std = hit[1] / (double)n_experiments;
 std = sqrt(std - mean * mean);
 printf(" %7.4f %6.4f",mean,std);
 fprintf(file,"%6.4f,",mean);
 mean = miss[0] / (double)n_experiments;
 std = miss[1] / (double)n_experiments;
 std = sqrt(std - mean * mean);
 printf(" %7.4f %6.4f",mean,std);
 fprintf(file,"%6.4f\n",mean);
 printf("\n");
 //
 // output the tree height data
 if(details != 0 | | n == atoi(argv[2]))
  printf(" i frac height\n");
  printf(" -----\n");
  for(int i = 0;i \le n;i++)
   if(h_height[i] != 0)
    printf(" %5d %11.9f\n",i,(double)h height[i] / (double)n experiments);
  printf(" -----\n");
 //
 // output the number of leaves data
 if(details != 0 | | n == atoi(argv[2]))
  printf(" i frac leaves\n");
  printf(" -----\n");
  for(int i = 0;i <= n;i++)
   if(h_leaves[i] != 0)
    printf(" %5d %11.9f\n",i,(double)h_leaves[i] / (double)n_experiments);
  printf(" -----\n");
 }
 //
 // done
 //
 fflush(stdout);
printf("done in %.1f seconds\n",elapsed_time());
return 0;
```

Descrição das funções desenvolvidas

Função tree_height

Para calcular a altura da árvore, se o node for nulo retornamos 0. Se não chamamos recursivamente a função com o node da esquerda e atribuimos o valor de retorno à variavel heigh_left e chamamos recursivamnete a função com o node da direita e atribuimos o valor de retorno à variavel height_right. Por fim se a altura da esquerda for maior que a altura da direita, retornamos a altura da esquerda mais um, para contabilizar o node atual, se não retornamos a altura da direita mais um.

Função search tree

Para procurar um dado na árvore, cada vez que a função é chamada incrementamos a variável search_counter. Se o node for nulo retornamos NULL, se o dado que estamos à procura for igual ao dado do node atual retornamos o node atual e por fim voltamos a chamar a própria função recursivamente com o dado a procurar e com o node da esquerda se o dado a procurar for menor que o dado do node atual e com o node da direita se o dado a procurar for maior que o dado do node atual.

Função count function calls on hit

Para calcular o custo de procurar um item presente na árvore, analisamos que o custo de procurar um certo node é igual ao nível onde esse node se encontra mais um. Logo criamos uma função recursiva que percorre a árvore e sempre que encontra um node nulo retorna 0 se não for nulo adiciona ao custo total o valor do nivel mais um.

Função count_function_calls_on_miss

Tal como anteriormente o custo de procurar um certo node é igual ao nível mais um. Logo criamos uma função recursiva que percorre a árvore e sempre que encontra um node nulo retorna 0 se não for nulo adiciona ao custo total o valor do nível mais um.

Código para representação dos gráficos

Para a representação dos gráficos e mais especificamente para o ajuste de curvas utilizámos código fornecido pelo professor nas aulas.

```
close all;
M = csvread('Data_100000.csv',1,0);
X=M(:,1);
%% Grafico maximum tree height (mean)
figure(1);
Y=M(:,4);
D=[log(X),1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico maximum tree height ')
legend("Mean","Curve fitting")
%% Grafico maximum tree height (min)
figure(2);
Y=M(:,2);
D=[log(X),1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico maximum tree height ')
legend("Minimo","Curve fitting")
%% Grafico maximum tree height (max)
figure(3);
Y=M(:,3);
D = [log(X), 1 + 0 * X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico maximum tree height ')
legend("Maximo","Curve fitting")
```

Código para representação dos gráficos

```
%plot(X,Y mod,'r');
%% Grafico number of leaves (mean)
figure(4);
Y=M(:,7);
D=[X,1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico number of leaves ')
legend("Mean","Curve fitting","Min","Max")
%% Grafico number of leaves (min)
figure(5);
Y=M(:,5);
D=[X,1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico number of leaves ')
legend("Min","Curve fitting")
%% Grafico number of leaves (max)
figure(6);
Y=M(:,6);
D=[X,1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico number of leaves ')
legend("Max","Curve fitting")
%% Grafico calls on hit (mean)
figure(8);
Y=M(:,8);
D=[log(X),1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
```

Código para representação dos gráficos

```
title('Grafico calls on hit (mean)')
legend("Mean","Curve fitting")

%% Grafico calls on miss (mean)
figure(9);
Y=M(:,9);
D=[log(X),1+0*X];
w=pinv(D)*Y
plot(X,Y,'b',X,D*w,'r');
title('Grafico calls on miss (mean)')
legend("Mean","Curve fitting")
```

Análise de resultados | Output

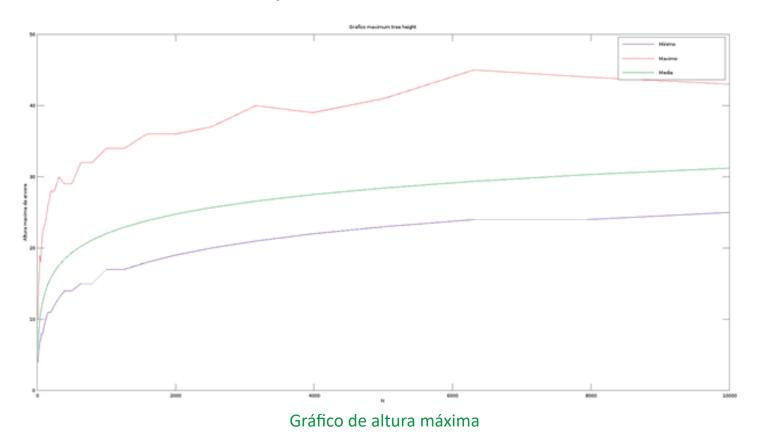
Para n=100000

Para 100000 árvores binárias aleatórias o calculo de todos os parametros demorou 508.9 segundos.

data for 100000 rar	ndom trees			
_	number of leave	es	calls on hit	calls on miss
	min max r		mean std	mean std
10 4 10 5.6407 0.9126	1 5	3.6633 0.7005	3.4432 0.3915	5.0393 0.3559
13 4 12 6.3992 1.0127	2 7	4.6678 0.7881	3.8482 0.4299	5.5019 0.3992
16 5 13 7.0355 1.0851	2 8	5.6690 0.8680	4.1819 0.4553	5.8771 0.4285
20 5 14 7.7409 1.1614	3 10	6.9967 0.9658	4.5564 0.4833	6.2918 0.4603
25 6 16 8.4612 1.2434	4 13	8.6708 1.0806	4.9357 0.5063	6.7074 0.4868
32 6 17 9.2811 1.3153	6 16	11.0011 1.2129	5.3720 0.5285	7.1789 0.5125
40 7 19 10.0438 1.3716	8 19	13.6594 1.3468	5.7741 0.5438	7.6088 0.5305
50 7 18 10.8045 1.4285	10 23	17.0038 1.5055	6.1748 0.5565	8.0341 0.5456
63 8 20 11.6175 1.4824	14 28	21.3324 1.6872	6.6013 0.5671	8.4825 0.5582
79 8 22 12.4343 1.5432	17 34	26.6695 1.8866	7.0299 0.5821	8.9295 0.5748
100 9 23 13.2745 1.5792	23 42	33.6733 2.1202	7.4727 0.5899	9.3888 0.5841
126 10 24 14.1280 1.6297	32 53	42.3349 2.381	1 7.9189 0.5999	9 9.8487 0.5952
158 11 26 14.9789 1.6744	41 64	53.0051 2.6503	3 8.3574 0.6062	2 10.2985 0.6024
200 11 28 15.8528 1.7152	53 79	67.0002 2.992	8 8.8144 0.615	7 10.7656 0.6127
251 12 28 16.7071 1.7445	69 98	84.0010 3.348	9.2576 0.621	9 11.2169 0.6194
316 13 30 17.5830 1.7839	87 121	105.6565 3.748	9.7127 0.629	4 11.6789 0.6274
398 14 29 18.4663 1.8148	114 150	132.9969 4.209	98 10.1641 0.62	96 12.1361 0.6280
501 14 29 19.3581 1.8481	146 191	167.3117 4.728	37 10.6181 0.63	24 12.5950 0.6312
631 15 32 20.2450 1.8635	186 233	210.6509 5.299	91 11.0733 0.63	63 13.0542 0.6352
794 15 32 21.1363 1.8937	238 290	264.9875 5.942	23 11.5285 0.63	82 13.5128 0.6374
1000 17 34 22.0328 1.912	304 361	333.6831 6.661	16 11.9867 0.63	90 13.9737 0.6384
1259 17 34 22.9428 1.935	2 385 454	420.0000 7.507	71 12.4430 0.64	10 14.4324 0.6405
1585 18 36 23.8439 1.944	7 493 568	528.6599 8.362	27 12.9010 0.63	99 14.8923 0.6395
1995 19 36 24.7606 1.978	627 705	665.3629 9.417	71 13.3566 0.64	20 15.3494 0.6417
2512 20 37 25.6774 1.989	788 880	837.6539 10.54	23 13.8205 0.64	139 15.8146 0.6437
3162 21 40 26.5947 2.010	3 1007 110	04 1054.3305 11.	.8457 14.2801 0	.6455 16.2753 0.6453
3981 22 39 27.5107 2.029	5 1274 139	6 1327.3027 13.	.3028 14.7367 0	.6451 16.7327 0.6449
5012 23 41 28.4263 2.045	3 1598 173	35 1671.0460 14.	.9880 15.1981 0	.6479 17.1949 0.6477
6310 24 45 29.3710 2.0650	2031 218	33 2103.6471 16.	.7691 15.6564 0	.6464 17.6538 0.6463
7943 24 44 30.3020 2.076	2 2567 273	80 2647.9810 18.	.7554 16.1194 0	.6477 18.1173 0.6476
10000 25 43 31.2254 2.0887	3247 342	26 3333.6365 21.	.0794 16.5789 0	.6479 18.5771 0.6478

done in 508.9 seconds

Análise de resultados | Gráficos



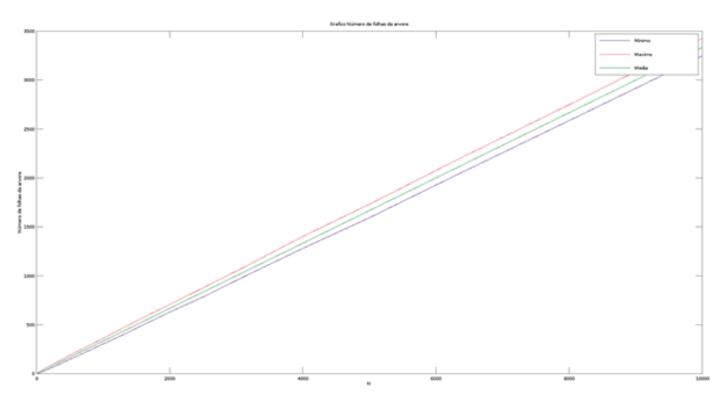
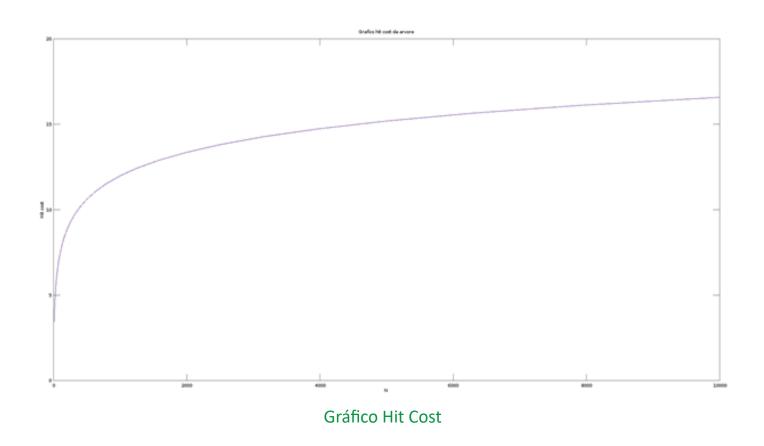
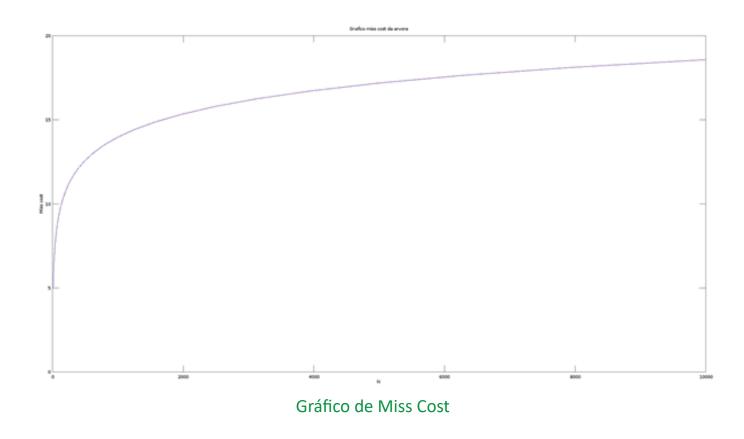


Gráfico de número de folhas





Análise de resultados | Ajuste de curvas

Ajuste de curvas

Ajuste de Curvas é um método que consiste em encontrar uma curva que se ajuste da melhor forma uma série de pontos. Neste caso vamos apresentar ajuste de curvas na forma de Alog(n)+B e An+B para cada curva referida em cima.

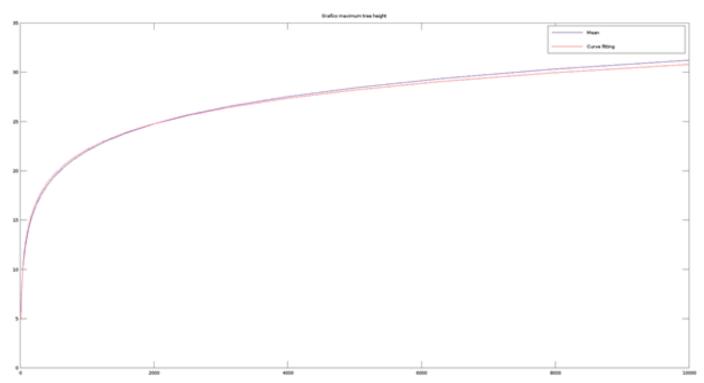


Gráfico de ajuste de curva á media da altura máxima de uma árvore com A=3.7468 e B=-3.7067

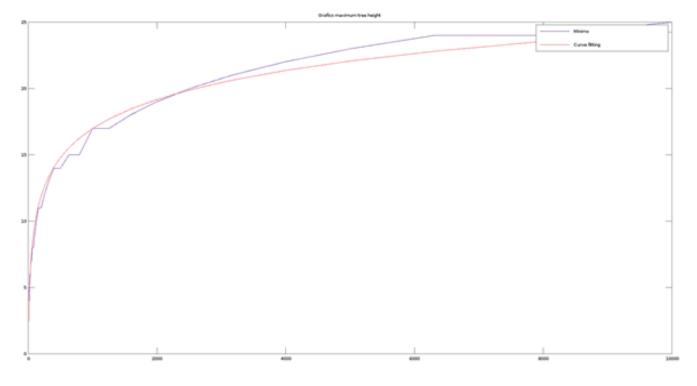


Gráfico de ajuste de curva ao minimo da altura máxima de uma árvore com A=3.1578 e B=-4.8272

Análise de resultados | Ajuste de curvas

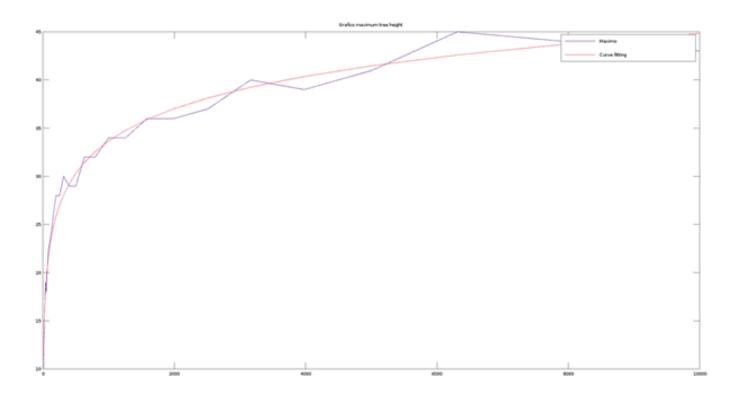


Gráfico de ajuste de curva ao máximo da altura máxima de uma árvore com A=4.8450 e B=0.1963

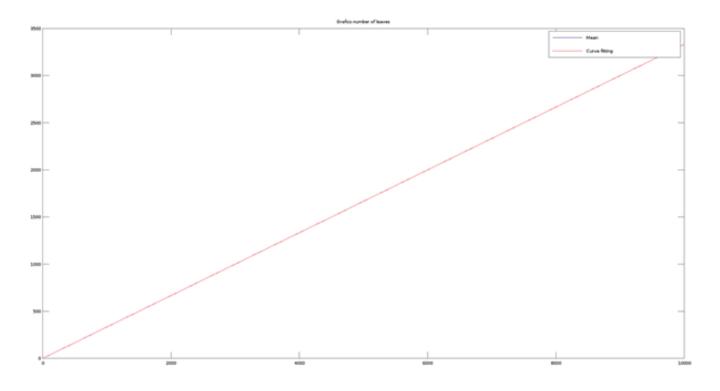


Gráfico de ajuste de curva á media do número de folhas de uma árvore com A=0.3333 e B=0.3336

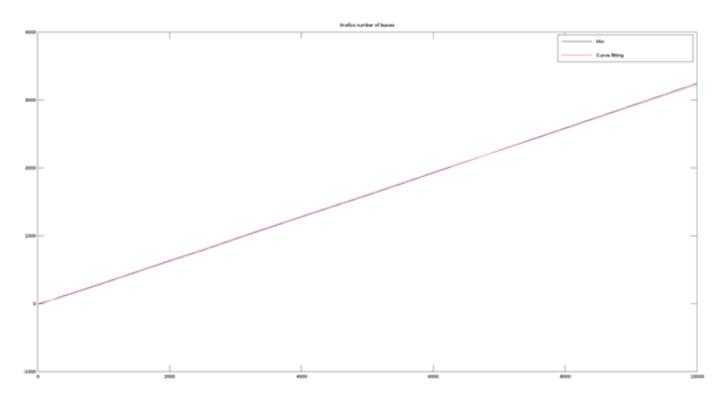


Gráfico de ajuste de curva ao minimo do número de folhas de uma árvore com A=0.3240 e B=-11.8311

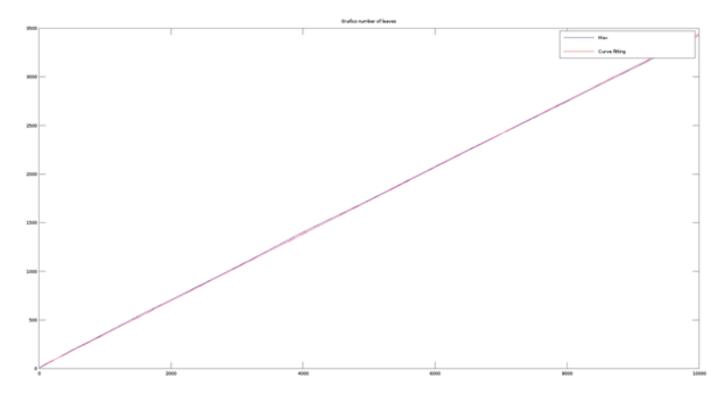


Gráfico de ajuste de curva ao máximo do número de folhas de uma árvore com A=0.3432 e B=11.3479

Análise de resultados | Ajuste de curvas

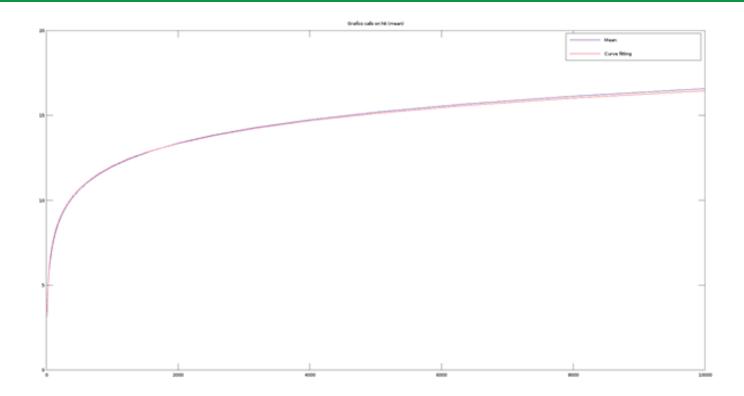


Gráfico de ajuste de curva á media de calls on hit de uma árvore com A=1.9263 e B=-1.2878

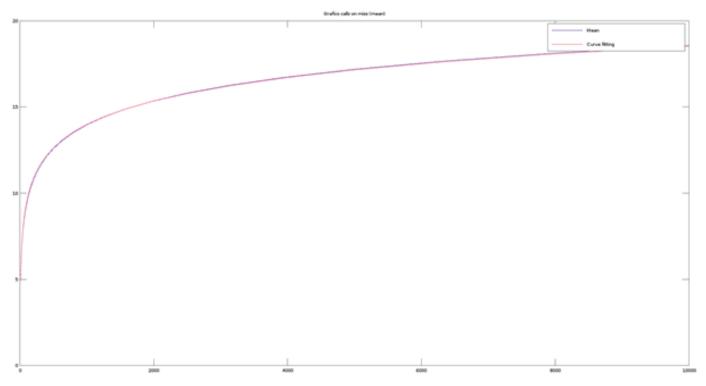


Gráfico de ajuste de curva á media de calls on miss de uma árvore com A=1.9733 e B=0.3527

Conclusões

Através da análise dos gráficos podemos retirar várias conclusões relativas a evolução de cada parâmetro à medida que o número de nodes aumenta.

Em relação à altura máxima de uma árvore binária podemos verificar que após o ajuste a uma curva, a altura mínima, média e máxima evoluem logaritimicamente, ou seja, no início a altura cresce muito rapidamente, mas acaba por estabilizar atingindo um valor máximo de 43 e um valor mínimo de 25.

Em relação ao número de folhas de uma árvore binária podemos verificar que após o ajuste a uma curva, a altura mínima, média e maxima evoluem linearmente, ou seja, no início o número de folhas cresce a um ritmo constante atingindo um valor máximo de 3247 e valor mínimo de 3426.

Em relação ao custo médio de procurar um item que está presente na árvore (hit cost) verificamos que evolui logariticamente, atingindo um valor máximo de 16.58.

Em relação ao custo médio de procurar um item que não está presente na árvore (miss cost) verificamos que evolui logariticamente, atingindo um valor máximo de 18.58.

Se inserirmos os números 1²,3²,..,(2n-1)² em vez dos números 1,3,...,(2n-1) em ordem aleatória na árvore conseguimos mudar o custo de computação do cálculo do custo médio de procurar um dado que não está presente na árvore. Se estamos à procura dos números 0,1,...,2n(2n-1), podemos concluir que todos os números que não sejam quadrados de um número inteiro impar não vão estar presentes na árvore.

Logo, com uma verificação se o número é quadrado de um inteiro ímpar podemos assim concluir se é necessário ou não procurar pelo mesmo.

Após a realização deste trabalho prático, concluímos que os objetivos propostos foram alcançados com sucesso. Conseguimos implementar todas as funções pretendidas, obtendo resultados satisfatórios e de acordo com a previsão, como já apresentados anteriormente. Com este trabalho, ambos os alunos do grupo fortaleceram os seus conhecimentos em diversos conceitos de programação abordados na Unidade Curricular de Algoritmos e Estruturas de Dados. É de salientar ainda que o trabalho de equipa e a superação de dificuldades foram fatores importantíssimos no sucesso do trabalho, melhorando as competências interpessoais de ambos os elementos do grupo.

Referências

https://en.wikipedia.org/wiki/Curve_fitting?fbclid=IwAR1ak4_u-FXtSD1596hOCVZ4I91BuvQ5vPiyTbZ-kpHLqMvpyuFiv4c0wxuI

https://www.geeksforgeeks.org/write-a-c-program-to-find-the--maximum-depth-or-height-of-a-tree/?fbclid=IwAR096qClNKCS6cKVcJFS9cU58HofNYEiNFTsV0UnHqx4XLeMZKenhD3qm-Y

https://www.geeksforgeeks.org/write-a-c-program-to-get-count-of-leaf-nodes-in-a-binary-tree/?fbclid=IwAR2jeg-HBJzZLSaKc8EPkXYuIMMn2KbYvVhE1FptFhfehNneGw5wf396AiY

Slides da Unidade Curricular de Algoritmos e Estruturas de Dados da Universidade de Aveiro